

SQUAD

MARY

JACKSON



# SQUAD



Ana Carolina Ramalho  
Dâmaris Lima de Oliveira  
Joyce Assis



Ludmilla Perucci dos Santos  
Marina Severo Morales  
Willa Regina Sena Evangelista





# EVOLUÇÃO DO CÂNCER

**Desafio:** Realizar uma análise exploratória e preditiva para identificar padrões temporais, regionais e demográficos relacionados à incidência de câncer no mundo, com foco em apoiar políticas públicas de prevenção.



# INTRODUÇÃO - POWER BI



# PREPARAÇÃO DO AMBIENTE

1. Importação das Bibliotecas
2. Importação do Data Frame `global_cancer_patients_2015_2024`
3. Análise das informações do Data Frame (como tipo de dados, existência de valores nulos e não-nulos, etc)



# PREPARAÇÃO DO AMBIENTE

## 1. Importação das Bibliotecas

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import plotly.express as px
import datetime
from sklearn.linear_model import LinearRegression
from statsmodels.tsa.seasonal import seasonal_decompose
```





# PREPARAÇÃO DO AMBIENTE

## 2. Importação do Data Frame global\_cancer\_patients\_2015\_2024

```
df = pd.read_csv('global_cancer_patients_2015_2024.csv')
df.head()
```

|   | Patient_ID | Age | Gender | Country_Region | Year | Genetic_Risk | Air_Pollution | Alcohol_Use | Smoking |
|---|------------|-----|--------|----------------|------|--------------|---------------|-------------|---------|
| 0 | PT0000000  | 71  | Male   | UK             | 2021 | 6.4          | 2.8           | 9.5         | 0.9     |
| 1 | PT0000001  | 34  | Male   | China          | 2021 | 1.3          | 4.5           | 3.7         | 3.9     |
| 2 | PT0000002  | 80  | Male   | Pakistan       | 2023 | 7.4          | 7.9           | 2.4         | 4.7     |
| 3 | PT0000003  | 40  | Male   | UK             | 2015 | 1.7          | 2.9           | 4.8         | 3.5     |
| 4 | PT0000004  | 43  | Female | Brazil         | 2017 | 5.1          | 2.8           | 2.3         | 6.7     |

| Obesity_Level | Cancer_Type | Cancer_Stage | Treatment_Cost_USD | Survival_Years | Target_Severity_Score |
|---------------|-------------|--------------|--------------------|----------------|-----------------------|
| 8.7           | Lung        | Stage III    | 62913.44           | 5.9            | 4.92                  |
| 6.3           | Leukemia    | Stage 0      | 12573.41           | 4.7            | 4.65                  |
| 0.1           | Breast      | Stage II     | 6984.33            | 7.1            | 5.84                  |
| 2.7           | Colon       | Stage I      | 67446.25           | 1.6            | 3.12                  |
| 0.5           | Skin        | Stage III    | 77977.12           | 2.9            | 3.62                  |



# PREPARAÇÃO DO AMBIENTE

## 3. Análise das informações essenciais do Data Frame

```
df.shape
```

```
(50000, 15)
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 50000 entries, 0 to 49999
Data columns (total 15 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Patient_ID            50000 non-null  object
1   Age                   50000 non-null  int64
2   Gender                50000 non-null  object
3   Country_Region        50000 non-null  object
4   Year                  50000 non-null  int64
5   Genetic_Risk           50000 non-null  float64
6   Air_Pollution         50000 non-null  float64
7   Alcohol_Use           50000 non-null  float64
8   Smoking               50000 non-null  float64
9   Obesity_Level          50000 non-null  float64
10  Cancer_Type            50000 non-null  object
11  Cancer_Stage           50000 non-null  object
12  Treatment_Cost_USD     50000 non-null  float64
13  Survival_Years         50000 non-null  float64
14  Target_Severity_Score  50000 non-null  float64
dtypes: float64(8), int64(2), object(5)
memory usage: 5.7+ MB
```





# PREPARAÇÃO DO AMBIENTE

## 4. Verificação de Existência de Números Nulos

```
df.isnull().sum()
```

|                |   |
|----------------|---|
|                | 0 |
| Patient_ID     | 0 |
| Age            | 0 |
| Gender         | 0 |
| Country_Region | 0 |
| Year           | 0 |
| Genetic_Risk   | 0 |

|               |   |
|---------------|---|
| Air_Pollution | 0 |
|---------------|---|

|             |   |
|-------------|---|
| Alcohol_Use | 0 |
|-------------|---|

|         |   |
|---------|---|
| Smoking | 0 |
|---------|---|

|               |   |
|---------------|---|
| Obesity_Level | 0 |
|---------------|---|

|             |   |
|-------------|---|
| Cancer_Type | 0 |
|-------------|---|

|              |   |
|--------------|---|
| Cancer_Stage | 0 |
|--------------|---|

|                    |   |
|--------------------|---|
| Treatment_Cost_USD | 0 |
|--------------------|---|

|                |   |
|----------------|---|
| Survival_Years | 0 |
|----------------|---|

|                       |   |
|-----------------------|---|
| Target_Severity_Score | 0 |
|-----------------------|---|



# PREPARAÇÃO DO AMBIENTE

## 5. Tratamento de Dados

```
#Excluir registros incoerentes (exemplo: câncer de próstata em mulheres)
df = df[~((df['Cancer_Type'] == 'Prostate') & (df['Gender'] == 'Female'))]

#Excluir registros incoerentes (exemplo: câncer de colo de útero em homens)
df = df[~((df['Cancer_Type'] == 'Cervical') & (df['Gender'] == 'Male'))]
```

```
#Tratamento do Câncer de Mama do homens
mama_homens = df[(df['Cancer_Type'] == 'Breast') & (df['Gender'] == 'Male')]
num_mama_homens_validos = int(0.01 * len(df[df['Cancer_Type'] == 'Breast']))
mama_homens_amostrados = mama_homens.sample(n=num_mama_homens_validos, random_state=42)
df = df[~((df['Cancer_Type'] == 'Breast') & (df['Gender'] == 'Male'))]
df = pd.concat([df, mama_homens_amostrados], ignore_index=True)
```



# #1. ANÁLISE EXPLORATÓRIA (EDA)

1. Identificar os países com maior número de casos.
2. Avaliar evolução temporal (2015–2024) da incidência.
3. Analisar diferenças por gênero, idade ou tipo de câncer (se disponível).
4. Detectar possíveis outliers ou anomalias nos dados.





# #1. ANÁLISE EXPLORATÓRIA (EDA)

## 1. Identificar os países com maior número de casos


```
qt_paises = df['Country_Region'].value_counts().reset_index(name='Incidencia')
qt_paises
```

|   | Country_Region | Incidencia |
|---|----------------|------------|
| 0 | Australia      | 4502       |
| 1 | USA            | 4460       |
| 2 | Germany        | 4420       |
| 3 | UK             | 4406       |
| 4 | Russia         | 4401       |
| 5 | India          | 4386       |
| 6 | Brazil         | 4378       |
| 7 | Pakistan       | 4340       |
| 8 | China          | 4279       |
| 9 | Canada         | 4268       |




# #1. ANÁLISE EXPLORATÓRIA (EDA)

## 1. Identificar os países com maior número de casos





## 2. Avaliar evolução temporal (2015–2024) da incidência





# #1. ANÁLISE EXPLORATÓRIA (EDA)

## 3. Analisar diferenças por gênero, idade ou tipo de câncer (se disponível)

```
qt_genero = df['Gender'].value_counts()
df['Gender'].value_counts(normalize=True) * 100
```

| proportion |           |
|------------|-----------|
| Gender     |           |
| Other      | 37.625456 |
| Female     | 33.293796 |
| Male       | 29.080748 |



# #1. ANÁLISE EXPLORATÓRIA (EDA)

## 3. Analisar diferenças por gênero, idade ou tipo de câncer (se disponível)

```
# Definindo as faixas etárias
bins = [20, 29, 39, 49, 59, 69, 79, 89]
labels = ['20-29', '30-39', '40-49', '50-59', '60-69', '70-79', '80-89']

# Agrupando as idades nas faixas
df['faixa-etaria'] = pd.cut(df['Age'], bins=bins, labels=labels, right=True, include_lowest=True)

# Contando quantas pessoas estão em cada faixa
contagem_por_faixa = df['faixa-etaria'].value_counts().sort_index()

print(contagem_por_faixa)

# Contagem por faixa
contagem = df['faixa-etaria'].value_counts().sort_index()

# Soma total de pessoas
total = contagem.sum()


# Exibir
print(f'\nTotal de pessoas: {total}')
```

```
faixa-etaria
20-29      6298
30-39      6306
40-49      6368
50-59      6129
60-69      6178
70-79      6314
80-89      6247
Name: count, dtype: int64
```



# #1. ANÁLISE EXPLORATÓRIA (EDA)


3. Analisar diferenças por gênero, idade ou tipo de câncer (se disponível)





# #1. ANÁLISE EXPLORATÓRIA (EDA)

## 3. Analisar diferenças por gênero, idade ou tipo de câncer (se disponível)



```
qt_tipo_cancer = df['Cancer_Type'].value_counts()
qt_tipo_cancer
```

| Cancer_Type | count |
|-------------|-------|
| Colon       | 6376  |
| Leukemia    | 6266  |
| Liver       | 6249  |
| Skin        | 6231  |
| Lung        | 6159  |
| Prostate    | 4195  |
| Cervical    | 4194  |
| Breast      | 4170  |



## #2. VISUALIZAÇÕES

1. Mapas de calor globais com incidência por país e ano.
2. Séries temporais por país ou continente.
3. Gráficos comparativos entre homens e mulheres.






## #2. VISUALIZAÇÕES

### 1. Mapas de calor globais com incidência por país e ano


Incidência de Pacientes por País e Ano






## #2. VISUALIZAÇÕES

### 3. Gráficos comparativos entre homens e mulheres




# #2. VISUALIZAÇÕES

## 2. Séries temporais por país ou continente



# #2. VISUALIZAÇÕES

## 2. Séries temporais por país ou continente






## #3. MODELAGEM PREDITIVA

1. Prever o número de casos em 2025 com base na evolução histórica usando regressão linear ou modelos de séries temporais.
2. Qual o impacto das variáveis, analisar e comparar todas.
3. Existe diferença significativa entre a incidência de cada tipo de câncer quando comparamos homens e mulheres?




## 1. Prever o número de casos em 2025 com base na evolução histórica usando regressão linear ou modelos de séries temporais






# #3. MODELAGEM PREDITIVA

## 2. Qual o impacto das variáveis, analisar e comparar todas





3. Existe diferença significativa entre a incidência de cada tipo de câncer quando comparamos homens e mulheres?



## #4. PROPOSTA DE INTERVENÇÃO

1. Com base nas análises, sugerir estratégias de prevenção prioritárias para países ou grupos mais afetados



### 1. Com base nas análises, sugerir estratégias de prevenção prioritárias para países ou grupos mais afetados

1. Entre 2015 e 2024, a América lidera em número de casos de câncer, com destaque para EUA e Brasil.
2. A distribuição por gênero é equilibrada, mas certos tipos afetam mais um dos sexos.
3. O aumento anual de casos está ligado a fatores como tabagismo, obesidade, poluição, álcool e risco genético.
4. É essencial que países mais afetados adotem políticas preventivas, como campanhas antitabagismo, incentivo a hábitos saudáveis e rastreamento precoce.
5. Educação em saúde e diagnóstico acessível podem reduzir a incidência e os custos, especialmente na América e Ásia.





# ORGANIZAÇÃO DA SQUAD

1. Reserva dos sábados para análise, discussão e realização dos exercícios, com presença marcante de Ana, Ludmilla e Marina;
2. Designação de Ana, Joyce, Dâmaris e Marina para apresentação do Desafio;
3. Realização de treino da apresentação nos dias 20/07 e 23/07, realizando os ajustes finais da apresentação.



# DESENVOLVIMENTO DO DESAFIO

## DIFICULDADES:

1. Desenvolver a modelagem preditiva de modo mais aprofundado;
2. Manter a presença contante de todos os membros do grupo nos encontros marcados.

## FACILIDADES:

1. Estabelecimento de prazos e responsabilidades;
2. Resolução dos exercícios no geral.







# OBRIGADA!

